



Fine-Tuning do AdaFace para Reconhecimento Facial em Vigilância

Adaptação de Domínio com Clipping Assimétrico e Módulos de Atenção

Cleiver Batista da Silva Junior · João Pedro de Castro Gomes Fernandes
Bianca Fernandes Visco · João Henrique Félix Simielli

Instituto de Informática — UFG | Visão Computacional | 2026

Contexto e Problema

Por que modelos de alta resolução falham em câmeras reais?

O Cenário

- Câmeras CCTV produzem faces de $\sim 20 \times 25$ px
- Desfoque, ruído de sensor, artefatos JPEG
- O AdaFace espera entrada de 112×112 px
- Upscale de 4,5x com informação insuficiente

O Problema do $\hat{z}$

O AdaFace usa a norma do embedding como proxy de qualidade.

Em batches de vigilância, todas as imagens são ruins — a 'menos pior' recebe $\hat{z} \approx +1$ e margem máxima, como se fosse uma imagem nítida.

Resultado: a loss penaliza o modelo por não reconhecer algo genuinamente irreconhecível.

Dataset: QMUL-SurvFace

Benchmark público de reconhecimento facial em vigilância real

220.888

imagens de treino

5.319

identidades de treino

10.640

pares de verificação

Resolução típica

~20×25 px

Protocolo de avaliação

Verificação open-set (1:1)

Split IDs treino/teste

Disjunto (sem sobreposição)

IDs com ≤ 5 imagens

48% do dataset

AdaFace: Arquitetura e Loss Adaptativa

A norma do embedding como proxy de qualidade da imagem



Fórmula da Margem Adaptativa

$$\text{margin} = m + h \times \hat{z} \times m$$

$\hat{z}$ alto (imagem boa) $\rightarrow$ margem maior $\rightarrow$ treino mais difícil | $\hat{z}$ baixo (imagem ruim) $\rightarrow$ margem menor $\rightarrow$ treino mais suave

Baseline: Inferência Zero-Shot

Desempenho do AdaFace pré-treinado (MS1MV2) aplicado diretamente ao QMUL-SurvFace

TAR @ FAR = 1%

6,6%

próximo ao aleatório em uso prático

AUC: 0,659 | Acc. best threshold: 61,97%

Detalhe por FAR

FAR Alvo	TAR Obtido
FAR = 10%	26,00%
FAR = 1%	6,60%
FAR = 0,1%	2,11%

Conclusão: a lacuna de domínio entre MS1MV2 e câmeras reais resulta em colapso de desempenho. Fine-tuning no domínio alvo é necessário.

Experimentos de Pré-Processamento (SR e Enhancement)

53 configurações testadas — nenhuma supera o baseline de forma relevante

Super-Resolução Genérica e Face-Specific (AUC)

Método	AUC	TAR@10%	Resultado
Baseline (sem SR)	0,699	28,78%	referência
Bicubic 4×	0,689	26,88%	≈ baseline
ESPCN 4×	0,685	25,53%	≈ baseline
BSRGAN 4×	0,629	21,56%	↓ identity loss
Real-ESRGAN 4×	0,613	18,72%	↓ identity loss
SwinIR 4×	0,610	18,05%	↓ identity loss
GFPGAN v1.4	0,680	26,43%	melhor face-specific
CodeFormer w=1,0	0,612	18,33%	↓ alucina IDs

Enhancement e TTA (melhor de cada grupo)

Método	AUC	vs. Base
Denoise Leve	0,697	+0,02%
TTA-2 (flip)	0,699	+0,18%
Ens(Base+GFPGAN)	0,697	+0,05%
SCPED+TTA-2	0,698	+0,04%

Por que o SR falha aqui?


- Identity loss: SR generativo alucina texturas plausíveis mas com traços de identidade errados
- Gargalo informacional: 20×25 px tem poucas features — nenhum SR cria informação nova real
- CLAHE destrói gradientes usados pelo MTCNN para alinhamento facial

Conclusão dos experimentos de pré-processamento

O melhor ganho de AUC com pré-processamento foi de apenas +0,18% (TTA-2 flip). SR avançado (BSRGAN, Real-ESRGAN, SwinIR) piorou em até −9,0%. Fine-tuning no domínio alvo é a única abordagem com ganho substancial.

Etapa 1: Fine-Tuning Simples

IResNet-50 + loss AdaFace original — 30 épocas no QMUL-SurvFace



42,3%

TAR@FAR=1% (época 20)

+35,7 pp

ganho vs zero-shot

Configuração

- Backbone: IResNet-50 (MS1MV2)
- SGD · LR backbone 0,001 · head 0,01
- Warmup 5 ép. + cosine annealing

Proposta 1: Clipping Assimétrico do $\hat{z}$

Modificação cirúrgica na loss AdaFace para domínios homogeneamente degradados


⚠ Problema Original

$\hat{z} \in [-1, +1]$: a imagem 'menos pior' do batch recebe $\hat{z} \approx +1$ e margem máxima — como se fosse nítida.

✓ Proposta

$\hat{z} \in [-1, +\alpha]$, $\alpha < 1$: nenhuma imagem de vigilância chega à margem máxima mesmo sendo a menos ruim.

TAR@FAR=1% por valor de α



Resultado

- Todos os $\alpha < 1$ superam o fine-tuning simples
- $\alpha = 0,7 \rightarrow \text{TAR} = 50,45\%$ (melhor)
- Implementação: 1 linha de código
- Insensível à escolha exata de α

Proposta 2: Módulos de Atenção CBAM e SE

Recalibrando o backbone para ignorar ruído e focar na geometria facial

SE Block (Squeeze-and-Excitation)

- Atenção por canal via avg-pool global
- Gargalo C/16 para compressão eficiente
- Suprime canais com ruído de sensor

CBAM (Canal + Espacial)

- Atenção de canal: avg-pool + max-pool combinados
- Atenção espacial: convolução 7×7 sobre o mapa
- Indica quê e onde focar no rosto degradado

Ablation Study — 10 épocas cada

Configuração	TAR@FAR=1%	AUC	EER
SE only	53,87%	88,39%	19,14%
CBAM only ← melhor	54,19%	90,89%	16,56%
SE + CBAM	53,48%	89,58%	18,07%

Resultado Final: SE + CBAM

Treino completo de 30 épocas — pico na época 10, overfitting após

TAR@FAR=1% — Modelo SE+CBAM



54,61%

TAR@FAR=1% (época 10)

90,94%

AUC máximo (época 5)


16,47%

EER mínimo (época 5)

⚠ Overfitting após época 10: loss de treino continua caindo mas TAR de verificação decresce — sinal de memorização das identidades de treino.

Comparativo Geral de Todas as Abordagens

Progressão de ganhos em TAR@FAR=1%



Meta: > 50% ✓ Atingida com clipping assimétrico ($\alpha=0,7$) e superada com módulos de atenção (54,61%)

Conclusões



Fine-tuning no domínio alvo é essencial: pré-processamento (SR, CLAHE, TTA) falha — o fine-tuning simples trouxe +35,7 pp.



Clipping assimétrico (1 linha de código): corrige a premissa quebrada do $\hat{Z}$ em batches homogêneos e adiciona +8 pp sobre o fine-tuning.



Módulos de atenção CBAM/SE: apenas 1,5% de parâmetros extras elevam o TAR para 54,61%, superando a meta de 50%.



CBAM isolado é mais eficiente: AUC 90,89% e EER 16,56% — combinar SE+CBAM cria redundância sem ganho.

Próximos passos: early stopping por validação · CBAM only + regularização · destilação de conhecimento · protocolo de identificação open-set