

Fine-Tuning do AdaFace para Reconhecimento Facial em Cenários de Vigilância: Adaptação de Domínio com Clipping Assimétrico e Módulos de Atenção

Cleiver Batista da Silva Junior, João Pedro de Castro Gomes Fernandes,

Bianca Fernandes Visco, João Henrique Félix Simielli

Instituto de Informática — Universidade Federal de Goiás (UFG)

Disciplina: Visão Computacional — Prof. Ricardo Augusto Pereira Franco

Resumo

Este trabalho investiga estratégias para adaptar o modelo AdaFace (Kim et al., CVPR 2022) ao domínio de reconhecimento facial em câmeras de vigilância, utilizando o dataset QMUL-SurvFace como ambiente de avaliação. O modelo AdaFace pré-treinado no MS1MV2, aplicado diretamente às imagens de vigilância (zero-shot), obteve TAR@FAR=1% de 27,5%, evidenciando a lacuna de domínio. A primeira etapa consistiu em fine-tuning direto do backbone IResNet-50 com a loss AdaFace original, atingindo 42,3%. Na segunda etapa, foram implementadas três modificações complementares: (1) clipping assimétrico do estimador de qualidade $\hat{z}$ no intervalo $[-1, +\alpha]$ com $\alpha < 1$, evitando que imagens homogeneamente degradadas recebam margens inadequadas; (2) inserção de módulos de atenção CBAM e SE nos blocos residuais do backbone; e (3) degradation augmentation específico para o domínio de CCTV. O modelo final com SE+CBAM atingiu TAR@FAR=1% de 54,61% no melhor checkpoint (época 10), representando ganho de +27,1 pontos percentuais sobre o zero-shot e +12,3 pp sobre o fine-tuning simples. O ablation study revelou que CBAM isolado produz o melhor AUC (90,89%) e menor EER (16,56%), sugerindo redundância quando SE e CBAM são combinados.

1. Introdução

Sistemas de reconhecimento facial modernos alcançaram desempenho próximo ao humano em benchmarks como LFW e MegaFace, onde as imagens são capturadas em condições controladas e com resolução elevada. Contudo, aplicações reais de videomonitoramento — câmeras CCTV em ruas, prédios e ambientes públicos — produzem imagens com resolução extremamente baixa, tipicamente faces de 20×25 pixels, sujeitas a desfoque de movimento, ruído de sensor, artefatos de compressão de vídeo e iluminação não controlada. Nesse cenário, o mesmo modelo que acerta 99% em LFW pode ter desempenho próximo ao aleatório.

O AdaFace [1], apresentado no CVPR 2022, representa o estado da arte em reconhecimento facial com imagens de qualidade variável. Seu diferencial central é o uso da norma do vetor de embedding como estimador implícito de qualidade da imagem: imagens nítidas produzem embeddings com norma elevada e recebem margem de aprendizado mais rigorosa (treino mais discriminativo), enquanto imagens borradas produzem normas baixas e recebem margem menor (evitando penalizar o modelo por informação genuinamente insuficiente). Essa propriedade torna o AdaFace particularmente adequado para cenários de vigilância — mas apenas se o modelo tiver sido adaptado ao domínio.

Este trabalho formula e avalia uma cadeia progressiva de adaptações do AdaFace ao domínio QMUL-SurvFace [2]: primeiro estabelece um baseline por inferência direta (zero-shot),

depois aplica fine-tuning simples, e por fim propõe e avalia modificações estruturais na arquitetura e na função de perda, com o objetivo de superar 50% de TAR@FAR=1%.

2. Formulação do Problema

O problema central é a discrepância de domínio entre o conjunto de pré-treinamento do AdaFace (MS1MV2: imagens web de alta resolução, grande diversidade de pose e iluminação) e o domínio alvo (QMUL-SurvFace: câmeras CCTV reais, faces minúsculas, degradação severa e homogênea).

Formalmente, dado um par de imagens faciais (I_1, I_2) capturadas por câmeras de vigilância, o objetivo é determinar se ambas pertencem à mesma identidade. O sistema produz uma pontuação $s = \cos(f(I_1), f(I_2)) \in [-1, +1]$, onde $f(\cdot)$ é o extrator de embeddings, e classifica o par como genuíno se $s \geq \tau$ para algum limiar τ . O desempenho é medido pelo TAR@FAR=k%, que fixa a taxa de falsos positivos em k% e mede a taxa de verdadeiros positivos correspondente — métrica padrão em reconhecimento facial de vigilância, pois reflete o regime operacional real onde falsos alarmes têm custo elevado.

Um problema específico identificado é que a loss AdaFace foi projetada pressupondo diversidade de qualidade dentro do batch: o estimador $\hat{z}$ normaliza a norma do embedding em relação à média e ao desvio padrão do batch atual. Em batches homogêneamente degradados — como os de vigilância — a premissa é violada: a imagem 'menos pior' do batch recebe $\hat{z} \approx +1$ e dispara a margem máxima, como se fosse uma imagem de alta qualidade, o que é conceitualmente incorreto e pode perturbar o treinamento.

3. Objetivos

Este trabalho tem os seguintes objetivos específicos:

- Estabelecer um baseline quantitativo do AdaFace IR-50 pré-treinado (MS1MV2) aplicado diretamente ao QMUL-SurvFace, sem adaptação de domínio.
- Avaliar o impacto do fine-tuning direto do backbone no domínio alvo, usando a loss AdaFace original.
- Propor e implementar o clipping assimétrico do estimador $\hat{z}$ como modificação cirúrgica na loss AdaFace, adequando o mecanismo de controle de qualidade ao domínio de vigilância.
- Propor e avaliar a inserção de módulos de atenção (SE e CBAM) no backbone IResNet-50, com o objetivo de suprimir ruído e focar nas regiões de geometria facial discriminativa.
- Conduzir um ablation study para quantificar a contribuição individual de cada módulo de atenção.
- Superar a marca de 50% de TAR@FAR=1% no protocolo oficial do QMUL-SurvFace.

4. Metodologia

4.1 Dataset: QMUL-SurvFace

O QMUL-SurvFace [2] é um benchmark público construído especificamente para reconhecimento facial em vigilância real. As imagens foram capturadas por câmeras de

segurança em condições não controladas, com faces em resolução tipicamente de 20×25 pixels, múltiplos ângulos de pose, oclusões parciais e iluminação variável.

A estrutura utilizada foi:

- Conjunto de treino: 5.319 identidades, 220.888 imagens (subpastas por identidade).
- Conjunto de verificação (teste): 9.913 imagens únicas, 5.320 pares genuínos e 5.320 pares impostores definidos pelos arquivos `positive_pairs_names.mat` e `negative_pairs_names.mat`.
- As identidades de treino e teste são disjuntas — protocolo open-set.

4.2 Modelo Base: AdaFace IR-50

O AdaFace utiliza um backbone IResNet-50 com 43,6M de parâmetros, que recebe imagens 112×112 pixels alinhadas por landmarks faciais e produz embeddings de 512 dimensões. A loss AdaFace aplica uma margem angular adaptativa ao logit da classe correta durante o treino:

$$\text{margin} = m + h \times \hat{z} \times m, \text{ onde } \hat{z} = \text{clamp}((\|z\| - \mu_{\text{batch}}) / \sigma_{\text{batch}}, z_{\text{min}}, z_{\text{max}})$$

sendo m a margem base (0,4), h a força da adaptação (0,333), s a escala dos logits (64) e $\hat{z}$ o estimador de qualidade normalizado pelo batch. Os pesos pré-treinados utilizados foram o checkpoint `adaface_ir50_ms1mv2.ckpt`, treinado no MS1MV2 com 5,8M imagens de 85.742 identidades.

4.3 Clipping Assimétrico do Estimador $\hat{z}$

A modificação proposta altera o intervalo de clipping do estimador de qualidade de $[-1, +1]$ (padrão original) para $[-1, +\alpha]$ com $\alpha < 1$. O raciocínio é: em domínios de vigilância, onde todas as imagens são degradadas, a imagem 'menos pior' de um batch ainda não é de alta qualidade e não deveria receber a margem máxima projetada para imagens nítidas.

Foram avaliados três valores de α : 0,3, 0,5 e 0,7. A modificação é cirúrgica — uma única linha na forward pass da AdaFaceHead — e preserva toda a capacidade de redução de margem para imagens ruins (limite inferior em -1).

4.4 Módulos de Atenção SE e CBAM

Os módulos SE (Squeeze-and-Excitation) [3] e CBAM (Convolutional Block Attention Module) [4] foram inseridos após a segunda convolução e antes da soma residual em cada bloco Bottleneck_IR do backbone, conforme:

- SE Block: recalibra os pesos por canal via global average pooling seguido de dois layers lineares com razão de redução 1/16, produzindo pesos de atenção por canal no intervalo $[0,1]$.
- CBAM Block: aplica atenção de canal (usando avg-pool e max-pool combinados) seguida de atenção espacial via convolução 7×7 sobre os mapas de ativação. O resultado é um mapa que indica simultaneamente quais canais e quais regiões espaciais são mais discriminativos.

O modelo IResNet50_CBAM resultante possui 44,0M de parâmetros no total, dos quais apenas 0,67M (1,5%) pertencem aos módulos de atenção — adição computacionalmente negligível. A posição de inserção foi escolhida para recalibrar as features brutas antes da soma residual, maximizando o impacto sem interromper o fluxo de gradiente principal.

4.5 Degradation Augmentation

O pipeline de treino incluiu augmentação de degradação para simular as condições reais de captura de vigilância: GaussianBlur com $\sigma \in [0,1; 1,5]$ (probabilidade 40%), ruído gaussiano com $\text{std} \in [0,01; 0,05]$ (probabilidade 30%) e compressão JPEG com qualidade 30–70 (probabilidade 30%), além de ColorJitter, RandomAffine e RandomHorizontalFlip como augmentações padrão.

4.6 Configuração de Treinamento

Os experimentos de fine-tuning foram conduzidos com a seguinte configuração:

Parâmetro	Valor
Backbone	IResNet-50 (43,6M parâmetros)
Pesos iniciais	adaface_ir50_ms1mv2.ckpt
Épocas	30
Batch size	64 (ablation) / 256 (fine-tuning simples)
Otimizador	AdamW (atenção) / SGD (fine-tuning simples)
LR backbone	1×10^{-4}
LR módulos de atenção / head	1×10^{-3}
Scheduler	Cosine annealing + warm-up linear (3 épocas)
Weight decay	5×10^{-4}
AMP	Backbone float16, head float32
Hardware	NVIDIA RTX 4090 (24 GB VRAM)

Tabela 1. Configuração dos experimentos de fine-tuning.

4.7 Protocolo de Avaliação

A avaliação seguiu o protocolo oficial do QMUL-SurvFace: extração de embeddings L2-normalizados das 9.913 imagens de verificação, cálculo da similaridade de cosseno para os 10.640 pares definidos, e reporte das métricas TAR@FAR=1% (métrica principal), AUC e EER. As identidades do conjunto de verificação são disjuntas do conjunto de treino, garantindo avaliação genuinamente open-set.

4.8 Experimentos de Pré-Processamento por Super-Resolução

Paralelamente ao fine-tuning, foram conduzidos 53 experimentos de pré-processamento com o objetivo de avaliar se técnicas de super-resolução (SR) e enhancement de imagem poderiam melhorar o desempenho do AdaFace pré-treinado sem retreinamento. Os experimentos foram organizados em dois notebooks (v2 e v3) e cinco grupos distintos, todos avaliados no protocolo oficial de verificação do QMUL-SurvFace com 10.640 pares (zero pares pulados).

O Grupo A testou super-resolução pura $4\times$ com métodos clássicos (Bicubic, Lanczos, ESPCN) e redes neurais generativas (BSRGAN, Real-ESRGAN, SwinIR). O Grupo B e C aplicaram um segundo estágio de upscale bicúbico ($2\times$ e $4\times$) sobre as saídas dos mesmos modelos SR. O Grupo D avaliou modelos especializados em restauração facial (GFPGAN v1.4, CodeFormer, VQFR v2, HAT-L). O Grupo E testou filtros clássicos de enhancement aplicados no espaço LAB (CLAHE, denoising, unsharp masking). O Grupo F avaliou Test-Time Augmentation (TTA) com diferentes combinações de flip e ajuste de brilho. Os Grupos G, H e I testaram ensembles de embeddings, substituição do detector MTCNN pelo SCRFD e pipelines combinadas, respectivamente.

5. Resultados

5.1 Baseline: Inferência Zero-Shot

O checkpoint pré-treinado `adaface_ir50_ms1mv2.ckpt`, aplicado diretamente ao conjunto de verificação do QMUL-SurvFace sem qualquer adaptação, obteve os seguintes resultados:

FAR alvo	TAR	AUC	Acurácia (melhor threshold)
10%	26,00%	0,659	61,97%
1%	6,60%	—	—
0,1%	2,11%	—	—

Tabela 2. Resultados do baseline zero-shot (sem fine-tuning).

Os resultados confirmam a lacuna de domínio: apesar do excelente desempenho do AdaFace em benchmarks de alta resolução, a aplicação direta a imagens de vigilância resulta em TAR@FAR=1% de apenas 6,6% — desempenho próximo ao aleatório para fins práticos.

5.2 Experimentos de Pré-Processamento

Os 53 experimentos de pré-processamento testados não superaram o baseline de forma relevante. A Tabela 3 apresenta os resultados dos métodos mais representativos de cada grupo.

Grupo	Método	AUC	TAR@FAR=10 %	vs. Baseline
A — SR Genérico	Baseline (sem SR)	0,699	28,78%	referência
A — SR Genérico	Bicubic 4×	0,689	26,88%	≈ baseline
A — SR Genérico	ESPCN 4×	0,685	25,53%	≈ baseline
A — SR Genérico	BSRGAN 4×	0,629	21,56%	↓ identity loss
A — SR Genérico	Real-ESRGAN 4×	0,613	18,72%	↓ identity loss
A — SR Genérico	SwinIR 4×	0,610	18,05%	↓ identity loss
D — Face-Specific	GFPGAN v1.4	0,680	26,43%	melhor face-sp.
D — Face-Specific	CodeFormer w=1,0	0,612	18,33%	↓ alucina IDs
E — Enhancement	Denoise Leve	0,697	28,29%	+0,02% AUC
E — Enhancement	CLAHE	0,571	14,12%	↓ piora muito
F — TTA	TTA-2 (flip)	0,699	27,82%	+0,18% AUC
G — Ensemble	Ens(Base+GFPGAN)	0,697	28,85%	melhor TAR@10%
H — Detector	SCRFD + TTA-2	0,698	27,63%	≈ baseline

Tabela 3. Resultados representativos dos experimentos de pré-processamento (53 configurações total).

Os resultados revelam um padrão consistente: nenhum método de pré-processamento superou o baseline de forma relevante. O maior ganho de AUC foi de apenas +0,18% com TTA-2 flip.

Em contraste, os modelos de SR generativo (BSRGAN, Real-ESRGAN, SwinIR) pioraram o AUC em até 9 pontos percentuais absolutos — fenômeno denominado identity loss: esses modelos alucinam texturas visualmente plausíveis mas com traços de identidade distintos dos originais, prejudicando exatamente os padrões de alta frequência que o AdaFace usa para discriminar identidades. O CLAHE foi particularmente prejudicial: em faces de $\sim 20 \times 25$ pixels, redistribui os gradientes de borda que o MTCNN utiliza para localizar landmarks, degradando o alinhamento e consequentemente o embedding. O SCRFD, detector superior ao MTCNN para faces pequenas, não traduz seu ganho de detecção em melhora de reconhecimento quando o gargalo é a resolução extremamente baixa das imagens.

5.3 Fine-Tuning Simples (1ª Etapa)

O fine-tuning direto do backbone IR-50 com a loss AdaFace original, por 30 épocas no QMUL-SurvFace, produziu melhora substancial. A Tabela 4 apresenta as métricas de verificação ao longo do treino:

Época	TAR@FAR=1 %	TAR@FAR=0, 1%	EER	AUC
5	27,64%	15,38%	27,51%	0,8034
10	37,24%	17,12%	24,86%	0,8327
15	39,10%	23,06%	24,11%	0,8388
20 (melhor)	42,30%	23,96%	23,59%	0,8449
25	40,76%	24,88%	23,52%	0,8463
30	40,96%	24,88%	23,56%	0,8462

Tabela 4. Métricas de verificação ao longo do fine-tuning simples.

O melhor checkpoint foi obtido na época 20, com TAR@FAR=1% = 42,3%, representando ganho de +35,7 pp sobre o zero-shot. A partir da época 20, as métricas de verificação estabilizaram ou oscilaram levemente, enquanto a acurácia de treino continuou crescendo — indicando início de overfitting às identidades de treino.

5.4 Experimento de Clipping Assimétrico

Três valores de α foram testados mantendo $z_{\min} = -1$ e variando $z_{\max} \in \{0,3; 0,5; 0,7\}$. Os melhores checkpoints de cada configuração foram avaliados no protocolo de verificação:

Configuração	TAR@FAR=10 %	TAR@FAR=1 %	TAR@FAR=0, 1%	AUC
$z_{\max} = 0,3$	73,57%	50,02%	28,48%	0,8926
$z_{\max} = 0,5$	72,89%	49,19%	33,12%	0,8862
$z_{\max} = 0,7$	73,05%	50,45%	31,64%	0,8873
Fine-tuning simples ($z_{\max}=1,0$)	71,64%	47,91%	23,06%	0,8834

Tabela 5. Comparação dos valores de $z_{\max}$ no clipping assimétrico.

Todas as três variantes de clipping assimétrico superaram o fine-tuning simples em todas as métricas. O valor $z_{\max} = 0,3$ obteve o maior AUC (0,8926) e TAR@FAR=1% de 50,02%, enquanto $z_{\max} = 0,7$ produziu o maior TAR@FAR=1% (50,45%). Ambos ultrapassaram a meta de 50%. As curvas de treino das três variantes foram praticamente idênticas em loss e acurácia de treino, confirmando que o clipping assimétrico atua principalmente na qualidade da generalização e não na velocidade de convergência.

5.5 Ablation Study: Módulos de Atenção

Para quantificar a contribuição individual de SE e CBAM, foram treinadas três variantes com 10 épocas cada, usando o mesmo protocolo e pesos iniciais:

Configuração	TAR@FAR=1%	AUC	EER
SE only (10 épocas)	53,87%	88,39%	19,14%
CBAM only (10 épocas)	54,19%	90,89%	16,56%
SE + CBAM (10 épocas)	53,48%	89,58%	18,07%

Tabela 6. Ablation study: contribuição individual dos módulos de atenção (10 épocas).

CBAM isolado produziu o melhor desempenho em todas as três métricas, com destaque para AUC de 90,89% e EER de 16,56% — o menor registrado em todos os experimentos deste trabalho. A combinação SE + CBAM ficou abaixo de ambas as variantes isoladas, indicando redundância: o CBAM já inclui atenção de canal em seu design (via ChannelAttention com avg-pool e max-pool), tornando o SE adicional redundante e potencialmente perturbando os gradientes dos parâmetros de atenção.

5.6 Resultado Final: SE + CBAM com Treino Completo

O modelo com SE + CBAM combinados, treinado por 30 épocas com o protocolo completo (clipping assimétrico $z_{\max}=0,7$, degradation augmentation, LR diferenciado), atingiu o melhor resultado registrado na época 10:

Época	TAR@FAR=1%	AUC	EER
5	53,65%	90,94%	16,47%
10 (melhor)	54,61%	89,53%	18,78%
15	52,03%	88,46%	19,42%
20	50,04%	87,83%	20,08%
30	48,20%	87,43%	20,56%

Tabela 7. Métricas de verificação do modelo SE+CBAM ao longo do treino.

A TAR@FAR=1% atingiu pico na época 10 (54,61%) e decresceu progressivamente mesmo com a loss de treino continuando a cair — fenômeno clássico de overfitting às identidades de treino. O modelo foi exportado em ONNX opset 17 com batch dinâmico (176,4 MB), diretamente integrável em sistemas com ONNX Runtime.

5.7 Comparativo Geral

Configuração	TAR@FAR=1%	Ganho vs zero-shot
Zero-shot (inferência direta)	6,6%	—
Fine-tuning simples (30 épocas)	42,3%	+35,7 pp
Clipping assimétrico $z_{\max}=0,3$	50,0%	+43,4 pp
Clipping assimétrico $z_{\max}=0,7$	50,5%	+43,9 pp
CBAM only — ablation (10 épocas)	54,2%	+47,6 pp
SE + CBAM — treino completo (época 10)	54,6%	+48,0 pp

Tabela 8. Comparativo geral de todas as configurações avaliadas.

6. Discussão e Análise

6.1 Por que o Pré-Processamento Não Supera o Baseline

Os resultados dos 53 experimentos de pré-processamento revelam quatro causas fundamentais para o fracasso das abordagens sem retreinamento.

Primeiro, o gargalo informacional é intransponível por transformações de pixel: imagens de $14\text{--}32 \times 11\text{--}39$ pixels possuem poucas features discriminativas, e nenhum método de SR ou enhancement cria informação nova real — apenas interpola ou alucina pixels plausíveis visualmente mas incorretos do ponto de vista de identidade.

Segundo, o identity loss nos modelos generativos é severo. Redes como Real-ESRGAN e SwinIR foram treinadas para maximizar métricas de qualidade perceptual (LPIPS, SSIM), não para preservar traços de identidade. O AdaFace é sensível exatamente aos padrões de alta frequência que esses modelos substituem por texturas genéricas.

Terceiro, o CLAHE é incompatível com o pipeline de alinhamento facial em resoluções tão baixas. A redistribuição de histograma local altera os gradientes de borda que o MTCNN usa para localizar landmarks, produzindo alinhamentos incorretos que degradam sistematicamente o embedding.

Quarto, o TTA produz pouca diversidade útil: com imagens tão degradadas, flip horizontal e variações de brilho geram embeddings quase idênticos ao original — a variância é dominada pelo ruído da câmera, não pelas augmentações. Esses resultados motivam e justificam a abordagem de fine-tuning no domínio alvo como única via de ganho substancial.

6.2 Por que o Clipping Assimétrico Funciona

O ganho consistente do clipping assimétrico sobre o fine-tuning simples valida a hipótese central: em domínios de vigilância, o estimador $\hat{z}$ calculado por z-score dentro do batch produz valores relativos que não correspondem à qualidade absoluta das imagens. Ao limitar o teto superior do $\hat{z}$, o modelo deixa de aplicar a margem máxima — projetada para imagens genuinamente de alta qualidade — a imagens que são apenas 'as menos ruins do batch'. A modificação preserva toda a capacidade de redução de margem para imagens realmente ruins (limite inferior em -1 mantido), sem requerer qualquer informação externa de qualidade.

O fato de $z_{\max} \in \{0,3; 0,5; 0,7\}$ produzirem resultados similares entre si, mas todos superiores ao $z_{\max}=1,0$, sugere que o efeito relevante é simplesmente evitar o valor extremo $+1$, e não a escolha precisa do teto. Isso é positivo do ponto de vista de robustez: a modificação não requer ajuste fino cuidadoso de α .

6.3 Por que CBAM Ajuda Mais que SE Isolado

Em imagens de vigilância de 20×25 pixels upsampled para 112×112 , uma parte significativa dos pixels corresponde ao fundo, cabelo e pescoço — não à geometria discriminativa do rosto. O backbone IR-50 treinado em imagens web de alta qualidade não foi otimizado para discriminar sinal facial de fundo ruidoso nesse cenário. O CBAM aborda isso de duas formas complementares: a atenção de canal suprime os canais que ativam em resposta a ruído e texturas de fundo, enquanto a atenção espacial pondera mais fortemente as regiões de geometria facial (olhos, nariz, contorno). O SE, por operar apenas no eixo de canal via avg-pool, captura menos informação discriminativa e é essencialmente uma versão mais fraca do módulo de canal do CBAM.

6.4 Overfitting a Partir da Época 10

O pico de $\text{TAR@FAR}=1\%$ na época 10 seguido de declínio progressivo, mesmo com loss de treino continuando a cair, é característico de overfitting ao espaço de identidades de treino. O dataset de treino relativamente pequeno (5.319 identidades, com 48% possuindo 5 ou menos imagens) cria condições favoráveis à memorização. A recomendação prática é usar early stopping baseado na métrica de verificação com avaliação mais frequente (a cada 2 épocas em vez de 5), e explorar regularizações adicionais como label smoothing e dropout mais agressivo.

7. Conclusão

Este trabalho demonstrou uma trajetória progressiva de adaptação do AdaFace ao domínio de vigilância, com ganhos mensuráveis e motivados teoricamente em cada etapa. O fine-tuning simples elevou o TAR@FAR=1% de 6,6% para 42,3% (+35,7 pp). O clipping assimétrico do estimador $\hat{z}$ — modificação de uma linha de código com fundamentação teórica clara — adicionou mais 8 pp, ultrapassando a barreira de 50%. A inserção de módulos CBAM nos blocos residuais, combinada com degradation augmentation e LR diferenciado, elevou o resultado para 54,61% (+12,3 pp sobre o fine-tuning simples).

O ablation study revelou que CBAM isolado é a configuração mais eficiente (AUC 90,89%, EER 16,56%), e que a combinação SE+CBAM introduz redundância sem ganho adicional. O modelo foi exportado em ONNX com batch dinâmico, sendo diretamente integrável em sistemas de monitoramento existentes.

Como trabalhos futuros, destacam-se: (1) aplicação de early stopping com avaliação mais frequente para mitigar overfitting; (2) uso de CBAM isolado como configuração principal, explorando treinos mais longos com regularização adicional; (3) combinação com destilação de conhecimento usando o modelo fine-tunado como professor para treinar versões mais leves; e (4) avaliação no protocolo de identificação open-set do QMUL-SurvFace (Rank-1, FNIR@FPIR).

Referências

- [1] KIM, Minchul et al. AdaFace: Quality Adaptive Margin for Face Recognition. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022. Disponível em: <https://arxiv.org/abs/2204.00964>
- [2] CHENG, Zhiyi et al. Surveillance Face Recognition Challenge (QMUL-SurvFace). In: IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018.
- [3] HU, Jie et al. Squeeze-and-Excitation Networks. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018.
- [4] WOO, Sanghyun et al. CBAM: Convolutional Block Attention Module. In: European Conference on Computer Vision (ECCV), 2018.
- [5] DENG, Jiankang et al. ArcFace: Additive Angular Margin Loss for Deep Face Recognition. In: CVPR, 2019.